



MASTER PROJECT DOCUMENT

Multimodal Skin Lesion Classification Using Image and Clinical Metadata

এই document-টা কী?

তোমার প্রজেক্টের সবগুলো ফাইল — PROJECT_PLAN.md, Project_Tracking.md, Dataset_Strategy.md, AI_Assistant_Instructions.md, PROJECT_OWNERSHIP.md — এই সবগুলো একসাথে মিলিয়ে বানানো **একটাই single reference**।

এখানে যা পাবে:

- প্রজেক্টের উদ্দেশ্য
- এখন পর্যন্ত কী কী হয়েছে (ownership নেওয়ার জন্য বিস্তারিত)
- কী বাকি আছে
- সামনের প্রতিটা ধাপে কী করতে হবে
- কোন কোন skill লাগবে

🔑 চিহ্নিত অংশগুলো **সবচেয়ে গুরুত্বপূর্ণ/টেকনিক্যাল** — এগুলোই supervisor বা viva-তে সবচেয়ে বেশি জিজ্ঞেস করা হবে।

📅 **সর্বশেষ আপডেট:** 2026-07-09



সূচিপত্র

Section

🎯 [Status Dashboard](#)

A [প্রজেক্টের পরিচয়](#)

B [Folder/File Ownership](#)

C [কালানুক্রমিক ইতিহাস \(Phase 1-5\)](#)

D 🔑 [Leakage Audit — সবচেয়ে গুরুত্বপূর্ণ আবিষ্কার](#)

E [বর্তমান Dataset অবস্থা](#)

F [এখনো যা বাকি](#)

Section

- G [সামনের Roadmap \(Phase 6-10\)](#)
 - H [প্রয়োজনীয় Skill ও জ্ঞান](#)
 - I [নিজে চালিয়ে দেখার Command](#)
 - J [Supervisor/Viva Talking Points](#)
-

Status Dashboard

১৫ সেকেন্ডে পুরো প্রজেক্টের ছবি

☒	Phase 1	Planning	সম্পূর্ণ
☐	Phase 2	Literature Review	চলমান (৩টা paper)
☒	Phase 3	Dataset Collection	সম্পূর্ণ (৪টা dataset)
☒	Phase 4	Dataset Preparation	সম্পূর্ণ
☒	Phase 5	EDA	সম্পূর্ণ
☐	Phase 6	Baseline Model	কোড শেষ, training বাকি
☐	Phase 7	Multimodal Fusion	শুরু হয়নি
☐	Phase 8	Experiments & Evaluation	শুরু হয়নি
☐	Phase 9	Thesis Writing	শুরু হয়নি
☐	Phase 10	Paper Submission	শুরু হয়নি

? প্রশ্ন

Dataset কি "ready"?

Model কি "trained"?

এখনকার blocker কী?

সবচেয়ে বড় technical অর্জন  ২২টা leakage/shortcut column খুঁজে বাদ দেওয়া

পরের কাজ কী

✅ উত্তর

হ্যাঁ — সম্পূর্ণ clean, leakage-free, documented

না — কোড আছে, কিন্তু একটাও training run সম্পূর্ণ হয়নি

GPU নাই → Kaggle-এ shift করার প্রস্তুতি চলছে

Kaggle-এ dataset mount → ৬টা baseline training run

Part A — প্রজেক্টের পরিচয়

 Research Title

Multimodal Skin Disease Classification System Using Skin Images and Clinical Metadata

Research Goal — ৪টা লক্ষ্য

1. একটি মানসম্পন্ন Master's thesis সম্পূর্ণ করা
2. বৈজ্ঞানিকভাবে অর্থপূর্ণ একটি multimodal AI system বানানো
3. একটি উপযুক্ত conference/journal-এ publish করা
4. Higher studies/scholarship-এর জন্য শক্তিশালী research profile তৈরি করা

Research Problem — আমরা কোন gap পূরণ করছি

বেশিরভাগ existing skin disease classification শুধু ছবি-ভিত্তিক (image-only)।

এদের দুর্বলতা:

- Clinical তথ্য ব্যবহার না করা
- Patient metadata কম ব্যবহার করা
- বাইরের dataset-এ দুর্বল generalization
- কম explainability
- Dataset bias

আমাদের সমাধান:

ছবি + clinical metadata + patient info + symptoms একসাথে ব্যবহার করে, multi-class (শুধু বাইনারি benign/malignant না) target করে, আর cross-dataset generalization + leakage-audit rigor যোগ করে — যেটা এখন পর্যন্ত reviewed কোনো paper একসাথে করেনি।

Working Philosophy (কাজের দর্শন)

- প্রতিটা সিদ্ধান্তে ব্যাখ্যা থাকা আবশ্যিক (কেন, বৈজ্ঞানিক যুক্তি, সীমাবদ্ধতা, বিকল্প)
- Reproducibility বজায় রাখা
- Raw data কখনো পরিবর্তন না করা
- প্রতিটা পরিবর্তনের log রাখা
- শুধু accuracy-এর জন্য optimize না করা

8টা Dataset-এর ভূমিকা

Dataset	ভূমিকা	কী আছে
 PAD-UFES-20	Primary/মূল dataset	ছবি + rich clinical metadata + patient info + symptoms
HAM10000	Benchmark dataset	Dermoscopic ছবি + সীমিত metadata
ISIC Archive 1	External validation	কোনো metadata নাই, শুধু ছবি
ISIC Archive 2	External validation (২য়)	ছবি + rich metadata, বেশিরভাগ column leakage-risk বলে বাদ

Part B — Folder/File Ownership

সব কোথায় আছে

```
Multimodal_Skin_Disease_Research/
├── README.md                প্রজেক্টের প্রথম পাতা
├── requirements.txt          প্রয়োজনীয় Python লাইব্রেরি
├── data/
│   ├── raw/                  IMMUTABLE – কোনো script কখনো এখানে লিখে না
│   │   ├── PAD_UFES20/, HAM10000/, ISIC_Archive_1/, ISIC_Archive_2/
│   ├── interim/             পরিক্ষার করার মাঝামাঝি ধাপের ফাইল
│   └── processed/            চূড়ান্ত, model-ready CSV
│       ├── <প্রতিটা dataset>/
│       │   ├── metadata_{train,val,test}.csv
│       │   ├── label_mapping.csv
│       │   ├── split_quality_report.csv
│       │   ├── dataset_description.md
│       │   └── feature_whitelist.md
├── docs/                     সব সিদ্ধান্ত ও ব্যাখ্যা এখানে
│   ├── PROJECT_PLAN.md      ক্যানোনিক্যাল প্ল্যান
│   ├── Project_Tracking.md   চলমান status + decision log
│   ├── Dataset_Strategy.md   dataset-এর ভূমিকা
│   ├── AI_Assistant_Instructions.md মূল working directive
│   ├── Dataset_Preparation_Final_Report.md cross-dataset verification
│   └── PROJECT_OWNERSHIP.md  file-by-file বিস্তারিত ব্যাখ্যা
└── src/
```

		data_audit/	Phase 4a – যাচাই কোড
		data_cleaning/	Phase 4b – পরিষ্কার, label, split কোড
		eda/	Phase 5 – বিশ্লেষণ কোড
		models/	Phase 6 – কোড লেখা শেষ, training বাকি
		evaluation/	Phase 6 – evaluation কোড
		notebooks/, reports/, logs/, papers/, _archive/	

📄 কোন file কী কাজ করে

File	কী বলে
🔑 PROJECT_PLAN.md	সব confirmed সিদ্ধান্ত — এটাই "আইন"
🔑 Project_Tracking.md	সবচেয়ে live/current ফাইল — "Session Handoff" দিয়ে শুরু
Dataset_Strategy.md	Dataset-এর role আর processing philosophy
AI_Assistant_Instructions.md	মূল কাজের নিয়মকানুন
Dataset_Preparation_Final_Report.md	Independent verification (overlap এখানে প্রথম ধরা পড়ে)
PROJECT_OWNERSHIP.md	প্রতিটা script/file-এর line-by-line ব্যাখ্যা

Part C — কালানুক্রমিকভাবে এখন পর্যন্ত কী হয়েছে

✅ Phase 1 — Planning

সম্পূর্ণ · 2026-06-29

- Thesis-এর scope ঠিক করা হয়েছে (multi-class, binary না)
- নিয়মকানুন লেখা হয়েছে (raw data read-only, missing value কখনো বানানো যাবে না, patient-wise split)
- ৩টা related paper review করে gap বের করা হয়েছে

● Phase 2 — Literature Review

চলমান

৩টা মূল paper পড়া হয়েছে:

- Mridha & Islam (2026)
- Suresh et al. (2026) — TG-CAVNet
- Watson et al. (2026)

🔑 **Watson et al.-এর সতর্কতা:** "diagnosis হওয়ার পরে তৈরি হওয়া field ব্যবহার করলে leakage হয়" — এটাই পরবর্তী পুরো leakage-audit কাজের মূল অনুপ্রেরণা।

✅ Phase 3 — Dataset Collection

সম্পূর্ণ

৪টা dataset `data/raw/`-এ সংগ্রহ করা হয়েছে।

✅ Phase 4 — Dataset Preparation

সম্পূর্ণ · 2026-07-07 → 2026-07-08

4a. Audit (যাচাই) — প্রতিটা dataset আলাদা করে

- সব ছবি খোলে কিনা, নষ্ট কিনা যাচাই — ৪টাতেই ০টা corrupted ছবি

🔑 **ISIC Archive 1-এ আসল data-quality সমস্যা ধরা পড়ে:** ১৫৫টা ছবি দুইটা ভিন্ন class-এ (label) একসাথে ফাইল করা ছিল (৭৮টা melanoma↔seborrheic keratosis, ৭৭টা actinic keratosis↔nevus) — আন্দাজে কোনটা সঠিক না ধরে, এই ছবিগুলো বাদ দেওয়া হয়েছে।

🔑 **PAD-UFES-20-এ ১৭৯ জন রোগীর একাধিক রোগ ধরা পড়ে** — তাই split করার সময় প্রতি রোগীর "dominant" (সবচেয়ে বেশি) রোগ ধরে stratify করা হয়েছে।

- HAM10000-এ কোনো patient identifier নাই — তাই `lesion_id` ধরে গ্রুপ করতে হয়েছে

- ISIC Archive 2-তে `patient_id` মাত্র ২% row-এ আছে — তাই `lesion_id` (fallback হিসেবে `image_id`) ব্যবহার করা হয়েছে

4b. Cleaning (পরিষ্কার)

- Column নাম একরকম করা (`gender`→`sex`, `region`→`anatomical_site`)

🔑 **লুকানো missing value ধরা:** PAD-UFES-20-এ `UNK` স্ট্রিং এবং HAM10000-এ `unknown` স্ট্রিং আসলে "তথ্য নাই" বোঝাচ্ছিল, কিন্তু সাধারণ `isna()` চেক এটা ধরতে পারেনি — আলাদা করে খুঁজে ঠিক করা হয়েছে।

- রোগের নাম একরকম করা (label mapping, প্রতিটার reason সহ)
- Patient/lesion-wise split (৭০/১৫/১৫), `seed=42`, প্রতিটাতে leakage শূন্য বলে verify করা হয়েছে

4c. 🔑 Cross-dataset overlap আবিষ্কার

2026-07-08

সব dataset আলাদাভাবে ঠিক হওয়ার পর, আরেকবার সব মিলিয়ে verify করার সময় একটা বড় জিনিস ধরা পড়ে:

জোড়া	Overlap
HAM10000 ↔ ISIC Archive 2	৯৮.৬% (প্রায় একই ছবি!)
ISIC Archive 1 ↔ ISIC Archive 2	৮১.৭%
HAM10000 ↔ ISIC Archive 1	৬৬.৫%
PAD-UFES-20 ↔ যেকোনো অন্য dataset	0% (কোনো overlap নাই)

✅ **সমাধান (fix b, global re-split-এর বদলে):** প্রতিটা dataset-এর নিজস্ব split অক্ষত রাখা হয়েছে, কিন্তু ISIC Archive-কে HAM10000-trained model-এর "external validation" হিসেবে ব্যবহার করার সময় overlapping ছবিগুলো বাদ দিতে হবে — এর জন্য `external_validation_exclusions.csv` বানানো হয়েছে:

Archive	মোট বাদ ব্যবহারযোগ্য থাকে
ISIC Archive 1	১,৩৬২টা ৬৮৫টা
ISIC Archive 2	৯,৮৭৩টা ১৫,২০৩টা

4d. Feature Whitelist তৈরি

বিস্তারিত → [Part D দেখো](#)

4e. Documentation cleanup

2026-07-08

পুরনো/conflict-করা doc (Research_Plan.md, Project_Cleanup_Review.md) _archive/-এ সরানো হয়েছে (মুছে ফেলা হয়নি), Dataset_Strategy.md in-place সংশোধন করা হয়েছে।

✓ Phase 5 — EDA

সম্পূর্ণ · 2026-07-09

প্রতিটা dataset-এর জন্য বানানো হয়েছে:

- Class distribution
- বয়স/sex/anatomical site distribution
- Fitzpatrick distribution (PAD-UFES-20)
- Missing-value chart
- Sample image grid
- **Image dimension distribution** (নতুন সংযোজন)

🔑 এই শেষেরটাই পরে ISIC Archive 2-এর bimodal 600×450/1024×1024 cluster ধরতে সাহায্য করে, যেটা আবার attribution column-এর সাথে হুবহু মিলে যায় — cross-dataset overlap-এর আরেকটা independent প্রমাণ।

Part D — 🔑 সবচেয়ে গুরুত্বপূর্ণ টেকনিক্যাল আবিষ্কার

Leakage / Shortcut Audit

এটাই এই প্রজেক্টের সবচেয়ে বড় টেকনিক্যাল contribution এই পর্যায়ে — supervisor/viva-তে সবচেয়ে বিস্তারিত বলার মতো অংশ।

সমস্যাটা কী? (সহজ ভাষায়)

Data-তে এমন কিছু column থাকতে পারে যেগুলো রোগের নামের সাথে প্রায় সরাসরি মিলে যায় — model তখন ছবি না দেখেই শুধু সেই column পড়ে "উত্তর" বলে দিতে পারে।

⚠️ এটা ধরা না পড়লে result fake ভাবে ভালো দেখাবে, কিন্তু বাস্তবে model কিছুই শেখেনি।

যা যা ধরা পড়েছে

(প্রতিটা real সংখ্যা দিয়ে verified, অনুমান না)

Dataset	Column	সমস্যা	প্রমাণ (সংখ্যা)
PAD-UFES-20	biopsed	১০০% malignant case-এ biopsy হয়েছিল, ব্যতিক্রম নাই	Phi = 0.80 , chi ² =1474.5, n=2,298
PAD-UFES-20	diagnostic_code	Label যেখান থেকে বানানো, ১:১ মিল	সরাসরি label-এর উৎস
HAM10000	diagnosis_confirm_type	সব malignant case histopathology দিয়ে confirm	Phi = 0.41 , chi ² =1700.67, n=10,015
HAM10000	diagnostic_code	Label-এর উৎস, ১:১ মিল	৭/৭ code unambiguous
ISIC Archive 1	class_label	Label-এর সরাসরি rename	৯/৯ class unambiguous
ISIC Archive 2	diagnosis_confirm_type	Malignant case কখনো "serial imaging"-এ confirm হয়নি	Phi = 0.36 , chi ² =3171.74, n=25,076
ISIC Archive 2	diagnosis_1/2/3/4/5	পুরো diagnostic hierarchy, label এখান থেকেই বানানো	diagnosis_3 = ১:১ label
ISIC Archive 2	concomitant_biopsy	diagnosis_confirm_type-এর সাথে হুবহু (duplicate সংকেত)	একই Phi = 0.36

Dataset	Column	সমস্যা	প্রমাণ (সংখ্যা)
ISIC Archive 2	 melanocytic	নিখুঁত বিভাজন — Melanoma/Nevus সব সময় True, বাকি ৭ class সব সময় False	০ ব্যতিক্রম, ১৭,৩৯৫+৭,৬৮১ row
ISIC Archive 2	attribution, copyright_license, image_type	Dataset-এর উৎস (হাসপাতাল) চিনিয়ে দেয়, ক্লিনিক্যাল না	attribution-এর একটা value = ঠিক HAM10000 overlap সংখ্যা (৯,৮৭৩) ৫টা field কখনোই Hospital Clinic/ViDIR row-এ populated না
ISIC Archive 2	 ৬টা sparse field	Missingness নিজেই source (হাসপাতাল) চিনিয়ে দেয়	

সারসংক্ষেপে

১৬টা column (leakage / label-source / non-clinical-administrative বিভাগে) + আলাদা ৬টা sparse field (source-institution leak প্রমাণিত, ২০২৬-০৭-০৯) = মোট ২২টা column, ৪টা dataset জুড়ে খুঁজে বের করে বাদ দেওয়া হয়েছে — প্রতিটার জন্য statistical প্রমাণ সহ, শুধু অনুমান না।

ফলাফল: প্রতিটা Dataset-এর জন্য একটা feature_whitelist.md

Dataset	মোট column	 Model-এ ব্যবহারযোগ্য
PAD-UFES-20	২৯	২১টা
HAM10000	১০	৩টা (age, sex, anatomical_site)
ISIC Archive 1	৬	০টা (শুধু ছবি)
ISIC Archive 2	৩০	৪টা active (age_approx, sex, anatom_site_1, anatom_site_general)

Part E — বর্তমান Dataset অবস্থা

এক নজরে

Dataset	Train	Val	Test	Class Imbalance
PAD-UFES-20	1,606	338	354	6 ~16:1
HAM10000	7,004	1,501	1,510	7 ~58:1
ISIC Archive 1	1,655	292	100	9 ~393:1 ⚠
ISIC Archive 2	17,535	3,769	3,772	9 ~63:1

⚠ ISIC Archive 1-এ ~393:1 imbalance — মাত্র ১টা sample একটা class-এ। এটাই সবচেয়ে বেশি imbalance (PROJECT_PLAN.md-এ ভুলবশত "239:1" লেখা ছিল, এখন সংশোধিত)।

✅ Dataset preparation সম্পূর্ণভাবে "ready":

- ছবি ও metadata clean, একসাথে যুক্ত (image_path দিয়ে, copy না করে)
- Leakage-free split (patient/lesion-wise, cross-dataset overlap handled)
- কোন column নিরাপদ তা নির্ধারিত (feature whitelist)
- সব সিদ্ধান্ত document করা

⚠ "Ready" মানে "trained" না — এখনো কোনো model আসলে পুরো data দিয়ে train হয়নি, শুধু code লেখা ও ছোট sample-এ test করা হয়েছে।

Part F — এখনো যা বাকি

Open Items (সংভাবে বলা)

📄 Documented সীমাবদ্ধতা

(এগুলো bug না, জেনেবুঝে রাখা সিদ্ধান্ত/সীমা)

- Cross-dataset overlap কমানো হয়েছে, পুরোপুরি মুছে ফেলা হয়নি — exclusion list সবসময় সক্রিয়ভাবে apply করতে হবে, automatic না
- HAM10000 ও ISIC Archive 2-তে সত্যিকারের patient-level control নাই (শুধু lesion/group-level)
- ISIC Archive 1 শুধু image-only, Test set খুবই ছোট ও imbalanced
- ISIC Archive 2-এর ৩টা column (anatom_site_2, anatom_site_special, dermoscopic_type) whitelist-এ আছে কিন্তু নিজস্ব missingness/attribution check এখনো বাকি
- ৩টা image-এ (ISIC_0028619, ISIC_0011126, ISIC_0011118) দুই archive-এর মধ্যে label-এ মতভেদ আছে — inherited, শুধু flag করা

☐ এখনো শুরু হয়নি

(correctly deferred)

- Literature review চলমান (আরও paper যোগ হবে)
- Fairness/bias analysis (Fitzpatrick, বয়স ভিত্তিক) — Phase 8-এ হবে

🔑 **Model training** — এখনো একটাও সম্পূর্ণ run হয়নি। Phase 6 Stage 1-এর কোড লেখা শেষ, GPU-না-থাকা confirm হয়েছে, কিন্তু কোনো checkpoint/metrics file তৈরি হয়নি — Kaggle-এ shift করার প্রস্তুতি চলছে (বিস্তারিত [Part G](#))।

Part G — সামনের Roadmap

বিস্তারিত (Phase 6-10)

☐ Phase 6 — Baseline Model Development

এখন চলছে

Stage 1 সিদ্ধান্ত (approved):

সিদ্ধান্ত	মান
Image branch	EfficientNet-B0 (কম overfitting risk, ছোট dataset-এর জন্য ভালো)
Metadata branch	Simple MLP
Loss/Metric	Class-weighted loss, macro-F1 প্রধান (accuracy না)
Seeds	৩টা প্রতি branch (মোট ৬টা run), mean±std রিপোর্ট
Image size	224×224 resize+pad, load-time-এ
Test split	একদম শেষে একবারই ব্যবহার

অবস্থা (২০২৬-০৭-০৯, *Project_Tracking.md*-এ log করা):

Stage 1-এর কোড (image + metadata branch) **লেখা শেষ**, কিন্তু এখনো কোনো **training run সম্পূর্ণ হয়নি** — কোনো checkpoint বা metrics file ডিস্কে তৈরি হয়নি। GPU নাই তা নিশ্চিত করা হয়েছে (`torch.cuda.is_available() == False`), তাই Kaggle-এ shift করার সিদ্ধান্ত হয়েছে এবং কোডে (`config.py`) প্রতিফলিত করা হয়েছে, কিন্তু Kaggle dataset upload/config এখনো বাকি।

🔑 এটাকে **"verified end-to-end"** বলা যাবে না যতক্ষণ না একটা আসল training/evaluation run checkpoint, metrics CSV, এবং evaluation report তৈরি করে।

☐ Phase 7 — Multimodal Fusion

Late fusion (ছবি+metadata feature জোড়া লাগানো) → তারপর cross-attention fusion (মূল contribution, লিটারেচার gap পূরণ)।

☐ Phase 8 — Experiments & Evaluation

- 🔑 **PAD-UFES-20 ↔ HAM10000 cross-dataset generalization** — headline result (এই জোড়ায় কোনো overlap নাই, সবচেয়ে পরিষ্কার তুলনা)
- HAM10000→ISIC external validation (exclusion filter সহ)
- Fitzpatrick skin-tone fairness analysis
- Bootstrap significance testing

☐ Phase 9-10 — Thesis Writing → Publication

arXiv preprint → workshop (ISIC @ MICCAI/CVPR) বা journal (Diagnostics, IEEE Access, Computers in Biology and Medicine)

Part H — প্রয়োজনীয় Skill ও জ্ঞান

এখনই বুঝতে হবে

(concept, code লেখা না লাগলেও)

- Train/Val/Test split, data leakage
- Class imbalance কেন শুধু accuracy বিভ্রান্তিকর (macro-F1 কেন লাগে)
- Overfitting কী

Basic Python

- pandas দিয়ে CSV পড়া/বোঝা (`df.head()`, `df['col'].value_counts()`)

Deep Learning concepts

(নাম চেনা, কাজ বোঝা যথেষ্ট)

- CNN, Pretrained model/Transfer learning, Loss function, epoch, batch

Tools

(হাতে কলমে শিখতে হবে)

- Git/GitHub (backup, version রাখা)
- Kaggle Notebooks (GPU দিয়ে training)
- Basic command line (`python -m src.models.train --branch image`)

সবচেয়ে গুরুত্বপূর্ণ (technical না হলেও critical)

প্রতিটা সিদ্ধান্তের "কেন" ব্যাখ্যা করতে পারা — biopsed leakage কেন বাদ দেওয়া হলো, patient-wise split কেন জরুরি, cross-dataset overlap কেন সমস্যা — এগুলো নিজের ভাষায় বলতে পারা viva-তে সবচেয়ে বেশি কাজে লাগবে।

Part I — নিজে চালিয়ে দেখার Command

১. সেটআপ (একবারই)

```
python -m venv .venv
.venv\Scripts\Activate.ps1
pip install -r requirements.txt
```

২. Audit (যেকোনো order-এ চালানো যায়)

```
.venv\Scripts\python.exe -m src.data_audit.run_audit_pad_ufoes20
.venv\Scripts\python.exe -m src.data_audit.run_audit_ham10000
.venv\Scripts\python.exe -m src.data_audit.run_audit_isic_archive_1
.venv\Scripts\python.exe -m src.data_audit.run_audit_isic_archive_2
```

৩. Cleaning (৪টা আগে শেষ হতে হবে, তারপর leakage-filter)

```
.venv\Scripts\python.exe -m src.data_cleaning.run_cleaning_pad_ufoes20
.venv\Scripts\python.exe -m src.data_cleaning.run_cleaning_ham10000
.venv\Scripts\python.exe -m src.data_cleaning.run_cleaning_isic_archive_1
.venv\Scripts\python.exe -m src.data_cleaning.run_cleaning_isic_archive_2
.venv\Scripts\python.exe -m src.data_cleaning.cross_dataset_leakage_filter
```

৪. EDA

```
.venv\Scripts\python.exe -m src.eda.eda_pad_ufoes20
.venv\Scripts\python.exe -m src.eda.eda_ham10000
.venv\Scripts\python.exe -m src.eda.eda_isic_archive_1
.venv\Scripts\python.exe -m src.eda.eda_isic_archive_2
.venv\Scripts\python.exe -m src.eda.eda_cross_dataset
```

✓ সফল হয়েছে কিনা যাচাই:

- reports/<Dataset>/-এ summary .md ফাইল তৈরি হয়েছে কিনা
 - corrupted_images.csv খালি কিনা
 - split_quality_report.csv error ছাড়া তৈরি হয়েছে কিনা
-

Part J — Supervisor/Viva Talking Points

১. "৪টা public dataset ব্যবহার করেছি, প্রতিটাতে rigorous audit করেছি — শুধু download করে ব্যবহার করিনি।"
২. "Patient-wise split ব্যবহার করেছি, image-wise না — এই field-এর একটা common ভুল এড়িয়েছি।"
৩. 🏆 "১৬টা leakage/label-source column + আলাদা ৬টা source-identity-leak sparse field (মোট ২২টা) খুঁজে বের করে বাদ দিয়েছি, প্রতিটা statistical প্রমাণ (phi coefficient) সহ — এটা প্রমাণ করে আমি critical ভাবে চিন্তা করেছি, শুধু model বানাইনি।" → সবচেয়ে শক্তিশালী পয়েন্ট
৪. "HAM10000 ও ISIC Archive আসলে একই source-এর ছবি — এই লুকানো overlap ধরেছি এবং documented ভাবে সমাধান করেছি।"
৫. "মূল contribution হবে cross-dataset generalization (PAD-UFES-20 ↔ HAM10000) — বেশিরভাগ paper এটা মাপে না।"

⚠️ একটা জরুরি নোট

এই document-টা তোমার existing ফাইলগুলো (2026-07-09 পর্যন্ত পড়া অবস্থা) ভিত্তি করে বানানো। যদি এরপর কোনো নতুন কাজ (যেমন Kaggle training result, sparse-field check-এর বাকি ৩টা column) হয়ে থাকে, সেগুলো এখানে নাই — Claude Code-কে জিজ্ঞেস করে Project_Tracking.md-এর সবচেয়ে উপরের "Session Handoff" অংশ পড়ে latest status নিশ্চিত করে নাও।